



Instituto Profesional de Líderes (IPL)

Ingeniería en Inteligencia Artificial

**OMNISAFETY AI: PLATAFORMA INDUSTRIAL MULTIMODAL PARA INSPECCIÓN AUTOMÁTICA,
MANTENIMIENTO PREDICTIVO Y ASISTENCIA OPERATIVA CON GOBERNANZA CLOUD**

Nombre: Alvaro Moreno

Ingeniería en Inteligencia Artificial

Materia: Proyecto Final

Programa de Especialización en Inteligencia Artificial

Profesor

Profesor: Raúl Figuera

Institución: Instituto Profesional de Líderes (IPL)

2026

Panamá, Panamá

RESUMEN

El presente proyecto desarrolla OmniSafety AI, un ecosistema integral de inteligencia artificial orientado a entornos industriales de manufactura pesada. La plataforma integra cuatro módulos funcionales: (1) visión por computadora para la detección de defectos superficiales y el monitoreo de equipo de protección personal (EPP) mediante YOLOv11; (2) análisis de series temporales para el mantenimiento predictivo de maquinaria rotativa mediante un enfoque híbrido XGBoost-LSTM; (3) procesamiento de lenguaje natural con arquitectura de generación aumentada por recuperación (RAG, por sus siglas en inglés) para la consulta de manuales técnicos; y (4) explicabilidad basada en SHAP para la validación de decisiones críticas. El sistema se despliega mediante contenedores Docker, con una API REST construida en FastAPI y un tablero interactivo desarrollado en Streamlit. La optimización con ONNX Runtime y TensorRT permitió alcanzar una latencia de inferencia de 12.4 ms por imagen, valor inferior al requisito de 100 ms establecido como objetivo. Los resultados experimentales, obtenidos sobre conjuntos de datos sintéticos validados de forma cruzada y reportados como promedio de cinco ejecuciones independientes, evidencian un mAP@0.5 de 0.837 en la detección de defectos, un ROC-AUC de 0.941 en la predicción de fallas y un recall@10 de 0.940 en el pipeline de

recuperación documental, con una tasa de cumplimiento de EPP del 87.3 % durante la simulación de un turno completo. El proyecto articula los saberes de los seis cuatrimestres del plan de estudios, aplicando la metodología CRISP-ML(Q) bajo un marco ágil Scrum.

Palabras clave: inteligencia artificial industrial, visión por computadora, mantenimiento predictivo, generación aumentada por recuperación, explicabilidad, YOLOv11, XGBoost, LSTM, SHAP, ONNX.

1. INTRODUCCIÓN

1.1 Planteamiento del problema

La industria manufacturera enfrenta pérdidas anuales estimadas en 1.3 billones de dólares debido a fallas no programadas de equipos, defectos de calidad no detectados y accidentes laborales vinculados con el incumplimiento de protocolos de seguridad (Li et al., 2026). Los sistemas tradicionales de inspección manual presentan tasas de error del 20 % al 30 %, mientras que el mantenimiento reactivo genera costos operativos entre tres y cinco veces superiores a los del mantenimiento predictivo (Zhang, 2026). A esta problemática se suma la fragmentación tecnológica: las plantas industriales suelen operar sistemas de visión, plataformas de telemetría y repositorios documentales que no comparten información entre sí, lo que impide explotar correlaciones de valor diagnóstico.

La convergencia de la Internet de las Cosas Industrial (IIoT), la visión por computadora avanzada y los modelos de lenguaje de gran escala abre la posibilidad de construir sistemas multimodales capaces de integrar datos heterogéneos —imágenes, series temporales y texto— en una única plataforma de toma de decisiones. No obstante, persisten tres desafíos críticos que este proyecto aborda de manera explícita: (a) la latencia de inferencia en tiempo real para

líneas de producción de alta velocidad; (b) la interpretabilidad de las predicciones para el cumplimiento normativo y la auditoría técnica; y (c) la escalabilidad en la nube con gobernanza y trazabilidad de los datos.

1.2 Justificación

El desarrollo de OmniSafety AI responde a la necesidad de una solución integral que conecte el piso de producción con la toma de decisiones estratégicas mediante inteligencia artificial explicable, auditable y optimizada para su despliegue en la nube. La integración de múltiples modalidades de datos en un mismo ecosistema reduce la fragmentación tecnológica y habilita correlaciones transversales que resultan inviables cuando cada módulo opera de forma aislada; por ejemplo, permite vincular anomalías de vibración con defectos de calidad observados en la inspección visual de la misma línea de producción.

Desde una perspectiva operativa, la plataforma contribuye a tres resultados concretos. Primero, reduce el tiempo de detección de defectos al automatizar la inspección con una latencia compatible con la velocidad de una línea real. Segundo, anticipa fallas mecánicas mediante el análisis de telemetría, lo que permite programar intervenciones antes de que ocurra una parada no planificada. Tercero, democratiza el acceso al conocimiento técnico al permitir consultas en lenguaje natural sobre manuales y procedimientos. Los tres

resultados se articulan en un tablero único que concentra el estado de la planta y las explicaciones de cada decisión automatizada.

1.3 Objetivos

1.3.1 Objetivo general

Desarrollar e implementar una plataforma multimodal de inteligencia artificial para la inspección automática, el mantenimiento predictivo y la asistencia operativa en entornos industriales, con énfasis en la explicabilidad, la baja latencia y la gobernanza en la nube.

1.3.2 Objetivos específicos

1. Implementar un sistema de detección de defectos superficiales industriales con YOLOv11 que alcance un mAP@0.5 superior a 0.80 y una latencia inferior a 100 ms por imagen.
2. Construir un modelo híbrido XGBoost-LSTM para la predicción de fallas en maquinaria rotativa con un ROC-AUC superior a 0.90.
3. Desarrollar un pipeline RAG para la consulta de documentación técnica con un recall@10 superior a 0.85.
4. Integrar explicabilidad mediante SHAP para la validación de decisiones críticas de seguridad.

5. Optimizar los modelos mediante cuantización INT8 y FP16 con ONNX Runtime y TensorRT.
6. Desplegar el ecosistema mediante contenedores Docker con API REST y tablero interactivo.
7. Verificar el cumplimiento de cada objetivo específico mediante evidencia cuantitativa y trazable.

1.4 Alcance y delimitaciones

El alcance del proyecto comprende el diseño, la implementación, la evaluación y el despliegue containerizado de los cuatro módulos descritos, junto con la integración de sus resultados en una API REST y un tablero de monitoreo. La validación se realiza sobre conjuntos de datos sintéticos generados con procedimientos de augmentación y modelos físicos simplificados, complementados con un corpus documental técnico de elaboración propia. Quedan fuera del alcance la puesta en marcha en una planta real, la certificación normativa del sistema, el entrenamiento de un modelo de lenguaje generativo propio y la operación continua con datos productivos. Estas delimitaciones se retoman en la sección 5.4 como limitaciones explícitas del trabajo.

1.5 Organización del documento

El documento se organiza en seis secciones. La sección 1 presenta el problema, la justificación y los objetivos. La sección 2 desarrolla el marco teórico de los cuatro dominios técnicos involucrados. La sección 3 describe la metodología de gestión, la arquitectura, los datos, los modelos y las métricas. La sección 4 expone los resultados con tablas, figuras y análisis estadístico. La sección 5 discute la interpretación de los hallazgos, la comparación con el estado del arte y las limitaciones. La sección 6 sintetiza las conclusiones. Finalmente, se incluyen las referencias y cuatro apéndices con información de reproducibilidad.

2. MARCO TEÓRICO

2.1 Visión por computadora industrial

La detección de defectos en superficies industriales presenta desafíos particulares: objetos pequeños, bajo contraste, fondos complejos y variaciones de escala (Li et al., 2026). Desde la irrupción de las arquitecturas de detección de una sola etapa (Redmon et al., 2016), la familia YOLO (You Only Look Once) se consolidó como el estándar de facto para aplicaciones en tiempo real. YOLOv11 representa una evolución de esta familia que incorpora mejoras en los bloques C3k2, atención distribuida y decodificación sin anclas. Investigaciones recientes demuestran que variantes mejoradas de YOLOv11 alcanzan un mAP@0.5 de 0.837 en el conjunto de datos NEU-DET y de 0.708 en el conjunto GC10-DET, este último de mayor complejidad (Li et al., 2026). Otros trabajos reportan valores intermedios: EMSD-YOLO alcanza 0.762 en GC10-DET (Zhang, 2026) y los modelos de detección de defectos en baldosas publicados en repositorios abiertos superan el 0.81 de mAP@0.5 en dominios de textura (Kocak, 2025).

La detección de equipo de protección personal (EPP) comparte la base arquitectónica de la detección de objetos, pero impone restricciones adicionales de eficiencia, ya que debe operar sobre flujos de video continuos en dispositivos

de borde. Las variantes YOLOv11n (nano) y YOLOv11m (medium) ofrecen un equilibrio adecuado entre precisión y velocidad para tareas de videovigilancia industrial, mientras que los modelos de mayor capacidad se reservan para la inspección de defectos, donde la exactitud es prioritaria sobre el costo computacional.

2.2 Mantenimiento predictivo basado en condición

El mantenimiento predictivo basado en condición (CBM, por sus siglas en inglés) utiliza señales de vibración, temperatura, presión y corriente eléctrica para estimar la vida útil remanente (RUL) de componentes mecánicos. En el plano algorítmico, los métodos de gradient boosting sobre árboles de decisión, formalizados por Chen y Guestrin (2016), han demostrado un desempeño sobresaliente en datos tabulares, mientras que las redes neuronales recurrentes de memoria de corto y largo plazo, propuestas originalmente por Hochreiter y Schmidhuber (1997), capturan dependencias temporales de largo alcance en la telemetría. Los enfoques híbridos que combinan ambos paradigmas superan a los modelos individuales porque explotan de manera simultánea patrones tabulares y dependencias temporales que ninguna de las dos familias captura por separado.

2.3 Generación aumentada por recuperación

La arquitectura RAG combina la recuperación de información densa mediante embeddings vectoriales con la generación de lenguaje natural, lo que permite que los modelos de lenguaje accedan a conocimiento externo actualizado (Lewis et al., 2020). En entornos industriales, el 72 % de los sistemas RAG en producción emplea búsqueda híbrida —densa y dispersa— y alcanza un recall@10 de 0.91, frente al 0.78 de la búsqueda densa pura (Golchian, 2026). Este hallazgo resulta relevante porque la terminología técnica industrial suele incluir códigos, referencias normativas y nombres de componentes que los embeddings densos representan de forma imperfecta, mientras que los métodos dispersos, como BM25, los recuperan con precisión.

2.4 Explicabilidad de la inteligencia artificial

La normativa emergente en materia de seguridad industrial exige que las decisiones críticas automatizadas sean interpretables y auditables. SHAP (SHapley Additive exPlanations) proporciona atribuciones basadas en la teoría de juegos cooperativos, pues satisface los axiomas de eficiencia, simetría, dummy y aditividad (Lundberg & Lee, 2017). TreeSHAP, su variante para modelos basados en árboles, permite obtener explicaciones en milisegundos, por lo que se ha convertido en la opción preferida para sistemas en producción (FutureAGI, 2026). Diversos estudios recientes subrayan que la explicabilidad no solo responde a exigencias regulatorias, sino que mejora la confianza del operador y facilita la adopción tecnológica en sectores críticos ("Explainable AI," 2026).

2.5 Optimización de modelos y despliegue

La cuantización posterior al entrenamiento a enteros de 8 bits reduce el tamaño del modelo en un factor de cuatro y acelera la inferencia en hardware compatible con Tensor Cores (Jacob et al., 2018). ONNX Runtime, con el proveedor de ejecución de TensorRT, permite desplegar modelos de visión con latencias reducidas en configuraciones optimizadas (ONNX Runtime, 2026). La literatura técnica coincide en que la ganancia de rendimiento depende del dominio y del tamaño del lote de inferencia, de modo que la verificación empírica en el hardware objetivo —y no la extrapolación teórica— constituye la práctica recomendada.

2.6 Síntesis del marco teórico y vacío identificado

Los cinco apartados anteriores convergen en una conclusión: existe evidencia sólida y abundante sobre cada módulo por separado, pero la literatura reporta con menor frecuencia sistemas que integren visión, series temporales y recuperación documental bajo una misma capa de servicios, con explicabilidad transversal y gobernanza de datos. Ese es precisamente el vacío que OmniSafety AI aborda. La Tabla 20 de la sección 5.2 contrasta los resultados obtenidos con los valores publicados, y el apartado 5.1 discute en qué medida la integración aporta valor más allá de la suma de sus componentes.

3. METODOLOGÍA

3.1 Enfoque metodológico y gestión del proyecto

El proyecto adopta el modelo CRISP-ML(Q), una adaptación de CRISP-DM que incorpora aseguramiento de calidad para proyectos de aprendizaje automático (Studer et al., 2021). Este modelo organiza el trabajo en seis fases iterativas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Sobre esa estructura se aplicó un marco ágil Scrum con sprints de dos semanas, doce en total, tal como se resume en la Tabla 1 y se ilustra en la Figura 1.

Tabla 1

Correspondencia entre las fases de CRISP-ML(Q), los sprints y los entregables verificables


Sprints	Fase de CRISP-ML(Q)	Actividades principales	Entregables verificables
1 – 2	Comprensión del negocio y de los datos	Definición de requisitos, análisis de factibilidad, levantamiento de fuentes de datos	Documento de requisitos y matriz de trazabilidad inicial
3 – 4	Preparación de los datos	Generación y augmentación de datos, ingeniería de variables, partición de conjuntos	Conjuntos de entrenamiento, validación y prueba versionados
5 – 6	Modelado	Entrenamiento de YOLOv11, XGBoost, LSTM y línea base de EPP	Pesos de modelos y registros de entrenamiento
7 – 8	Modelado y	Implementación del	Índice vectorial e

	evaluación	pipeline RAG, integración de SHAP y validación cruzada	informes de explicabilidad
9 – 10	Despliegue	Exportación a ONNX, cuantización INT8 y FP16, containerización	Modelos optimizados e imágenes Docker
11 – 12	Evaluación y despliegue	Pruebas de integración y de carga, documentación y verificación de objetivos	Pruebas automatizadas e informe final

Nota. Elaboración propia. Cada sprint incorporó las ceremonias de planificación, sincronización diaria, revisión y retrospectiva.

Figura 1

Planificación de los doce sprints y su correspondencia con las fases de CRISP-ML(Q)



Nota. Elaboración propia. La línea punteada agrupa los sprints en tres bloques bimestrales de trabajo.


La definición de terminado (Definition of Done) exigió cuatro condiciones acumulativas para cerrar cada incremento: código revisado por un par, cobertura de pruebas unitarias superior al 80 %, documentación actualizada y métricas de

rendimiento verificadas contra el umbral comprometido. Este criterio de aceptación evitó que se declarara concluida una funcionalidad sin evidencia cuantitativa, práctica que se refleja directamente en la sección 4.7.

3.2 Arquitectura del sistema

El ecosistema OmniSafety AI se estructura en cuatro capas con responsabilidades claramente separadas, lo que facilita el mantenimiento, las pruebas independientes y el escalamiento horizontal. La Figura 2 presenta la arquitectura de referencia y la Tabla 2 detalla las tecnologías y responsabilidades de cada capa.

Figura 2
Arquitectura de referencia de OmniSafety AI organizada en cuatro capas



Nota. Elaboración propia. Las flechas indican el flujo de datos desde la ingesta hasta la capa de presentación.

Tabla 2
Capas arquitectónicas, tecnologías y responsabilidades

Capa	Tecnologías	Responsabilidad principal	Modo de escalamiento
Ingesta	Cámaras industriales de 640 × 640 a 30 fps, sensores IIoT y repositorios documentales	Captura y normalización de datos heterogéneos	Escalamiento horizontal por número de líneas de producción
Datos	SQL y NoSQL para telemetría, ChromaDB para vectores y almacenamiento de objetos para modelos	Persistencia, versionado y trazabilidad de datos y artefactos	Particionado por planta y réplica de lectura
Inteligencia artificial	YOLOv11-L, XGBoost y LSTM, Sentence-Transformers con ChromaDB y SHAP	Inferencia multimodal y generación de explicaciones	Réplicas sin estado detrás de un balanceador

Presentación	FastAPI, Streamlit y exportación de reportes	Exposición de servicios y visualización operativa	Escalamiento horizontal del servicio de API
--------------	--	---	---

Nota. Elaboración propia con base en la implementación desarrollada.

3.3 Datos y preparación

3.3.1 Datos de visión

Para la detección de defectos se construyó un conjunto de datos sintético generado con procedimientos de augmentación que reproducen condiciones industriales reales: variaciones de iluminación, ruido gaussiano, oclusión parcial y deformaciones geométricas. Las anotaciones siguen el formato estándar de YOLO, con cajas delimitadoras normalizadas respecto de las dimensiones de la imagen. El conjunto comprende seis clases de defecto y se distribuyó en subconjuntos de entrenamiento, validación y prueba según se detalla en la Tabla 3.

Tabla 3

Distribución del conjunto de datos de visión por clase de defecto

Clase de defecto	Entrenamiento	Validación	Prueba	Total	Proporción del total
Grieta	720	90	180	990	19.4 %
Corrosión	660	82	165	907	17.7 %
Abolladura	600	75	150	825	16.1 %
Rayadura	700	88	175	963	18.8 %
Mancha	560	70	140	770	15.1 %
Poros	480	60	120	660	12.9 %
Total	3 720	465	930	5 115	100.0 %

Nota. Elaboración propia. La partición respeta la estratificación por clase para evitar desbalance entre subconjuntos.

Para el módulo de EPP se aplicó aprendizaje por transferencia a partir de pesos preentrenados en el conjunto COCO, con ajuste fino sobre imágenes de entornos industriales que incluyen cascos, chalecos, guantes, gafas y arneses, además de las clases negativas correspondientes a su ausencia.

3.3.2 Datos de series temporales

Se generaron datos sintéticos correspondientes a cinco máquinas, con 10 000 muestras temporales por máquina y siete variables de telemetría, descritas en la Tabla 4. La degradación hacia la falla se modeló mediante funciones sigmoideas que incrementan la vibración y la temperatura mientras reducen la presión y las revoluciones por minuto en las últimas 500 muestras de cada serie, lo que produce un escenario de falla progresiva verificable.

Tabla 4

Variables de telemetría y su comportamiento durante la degradación

Variable	Unidad	Frecuencia de muestreo	Comportamiento en la fase de degradación
Vibración en eje X	mm/s	1 kHz	Incremento progresivo con armónicos de defecto
Vibración en eje Y	mm/s	1 kHz	Incremento moderado y mayor dispersión
Vibración en eje Z	mm/s	1 kHz	Incremento pronunciado; principal indicador

			de falla
Temperatura del motor	°C	1 Hz	Tendencia creciente con componente cíclico diurno
Temperatura del rodamiento	°C	1 Hz	Incremento acelerado en las últimas 200 muestras
Presión hidráulica	bar	10 Hz	Descenso sostenido con mayor ruido de proceso
Corriente del motor	A	1 Hz	Incremento gradual con picos de arranque
Revoluciones por minuto	rpm	10 Hz	Descenso proporcional a la carga creciente

Nota. Elaboración propia. Las frecuencias declaradas corresponden a la configuración del generador sintético.

3.3.3 Corpus documental

Se construyó un corpus de manuales técnicos industriales en español e inglés que cubre procedimientos de seguridad, diagnóstico de fallas mecánicas, calibración de instrumentos y protocolos de emergencia. La segmentación se realizó con RecursiveCharacterTextSplitter en fragmentos de 512 tokens con solapamiento de 50 tokens, política que preserva el contexto entre fragmentos contiguos y evita la pérdida de información en los límites.

3.3.4 Partición de los conjuntos y control de fuga de información

La Tabla 5 resume la partición de los tres conjuntos de datos. En el módulo de visión la partición es estratificada por clase; en el módulo de series temporales la partición es temporal por máquina, de manera que ninguna ventana de prueba comparte muestras de origen con las ventanas de entrenamiento; y en el corpus documental la partición se realizó a nivel de documento, no de fragmento, para impedir que fragmentos del mismo manual aparecieran simultáneamente en indexación y evaluación.

Tabla 5

Partición de los conjuntos de datos y criterio de control de fuga de información

Módulo	Entrenamiento	Validación	Prueba	Criterio de partición
Visión (imágenes)	3 720	465	930	Estratificada por clase de defecto
Series temporales (ventanas de 256 pasos)	21 525	3 075	6 150	Temporal y por máquina, sin solapamiento de origen
Corpus documental (fragmentos)	873	No aplica	374	Partición por documento; 120 consultas anotadas para evaluación

Nota. Elaboración propia. En el módulo RAG la evaluación se realiza sobre consultas con fragmento relevante anotado manualmente.

3.4 Implementación de los modelos

3.4.1 Detección de defectos con YOLOv11

Se empleó la variante YOLOv11-Large, cuya arquitectura combina un backbone CSPDarknet optimizado con bloques C3k2, un cuello PANet con conexiones bidireccionales y una cabeza desacoplada sin anclas. Las seis clases de defecto consideradas son grieta, abolladura, rayadura, corrosión, mancha y poro. Los hiperparámetros de entrenamiento se detallan en la Tabla 6.

Tabla 6

Hiperparámetros de entrenamiento del modelo de detección de defectos

Componente	Configuración
Arquitectura	YOLOv11-Large (yolo11l.pt)
Resolución de entrada	640 × 640 píxeles
Optimizador	AdamW con tasa de aprendizaje 0.001 y decaimiento de pesos 0.0005
Planificador de tasa	Cosine annealing con calentamiento de 3 épocas
Épocas	100 con parada temprana (paciencia de 20 épocas)
Tamaño de lote	16
Augmentación	Mosaic, MixUp, Copy-Paste y variación de matiz, saturación y valor
Función de pérdida	Suma ponderada de pérdidas de cajas, clases y distribución

Nota. Elaboración propia. La parada temprana se monitoreó sobre la métrica mAP@0.5 del conjunto de validación.

3.4.2 Mantenimiento predictivo con ensemble XGBoost-LSTM

La ingeniería de variables produjo cuatro familias de características: estadísticas de ventana móvil (media y desviación estándar), tasas de cambio (primera y segunda derivada), componentes frecuenciales obtenidas mediante transformada de Fourier y medidas de entropía de señal. Sobre esa base se entrenaron un modelo XGBoost y una red LSTM, cuyo promedio ponderado constituye el ensemble. La Tabla 7 resume la configuración de ambos componentes.

Tabla 7

Hiperparámetros de los componentes del modelo híbrido

Componente	Hiperparámetro	Valor
XGBoost	Número de estimadores	500
XGBoost	Profundidad máxima	8
XGBoost	Tasa de aprendizaje	0.05
XGBoost	Submuestreo por árbol y por columna	0.8 y 0.8
XGBoost	Función objetivo	binary:logistic
LSTM	Capas bidireccionales	2
LSTM	Tamaño de estado oculto	128
LSTM	Deserción	0.3
LSTM	Longitud de secuencia	256 pasos temporales
LSTM	Optimizador	Adam con tasa de aprendizaje 0.001
Ensemble	Ponderación	$0.6 \cdot \text{XGBoost} + 0.4 \cdot \text{LSTM}$

Nota. Elaboración propia. La ponderación se seleccionó mediante el análisis de sensibilidad presentado en la Tabla 14.

3.4.3 Pipeline RAG

El pipeline combina recuperación densa y dispersa. Para la primera se empleó el modelo de embeddings all-MiniLM-L6-v2, de 384 dimensiones, reconocido por su eficiencia en tareas de similitud semántica (Reimers & Gurevych, 2019); para la segunda se implementó BM25. Los resultados de ambos recuperadores se fusionaron mediante combinación recíproca de rangos. La Tabla 8 detalla la configuración completa.

Tabla 8

Configuración del pipeline de recuperación aumentada

Componente	Configuración
Modelo de embeddings	sentence-transformers/all-MiniLM-L6-v2 (384 dimensiones)
Almacén vectorial	ChromaDB con distancia coseno
Recuperador disperso	BM25 con tokenización técnica y normalización de códigos
Estrategia de fusión	Combinación recíproca de rangos con peso 0.5 para cada recuperador
Segmentación	Fragmentos de 512 tokens con solapamiento de 50 tokens
Recuperación	Cinco fragmentos por consulta en la configuración base
Generación	Plantilla con contexto inyectado y trazabilidad de la fuente

Nota. Elaboración propia. La generación con un modelo de lenguaje ajustado se plantea como trabajo futuro.

3.4.4 Monitoreo de equipo de protección personal

El módulo de EPP reutiliza la arquitectura de detección con un modelo de menor capacidad, ajustado para reconocer cascos, chalecos, guantes, gafas y arneses, así como sus ausencias. La lógica de alerta evalúa tres condiciones simultáneas: presencia de la clase de riesgo, ausencia del EPP correspondiente y permanencia en zona restringida durante un mínimo de un segundo, lo que reduce los falsos positivos asociados a detecciones aisladas.

3.5 Optimización y aceleración

La optimización se ejecutó en tres etapas consecutivas. La primera consistió en la exportación del modelo de visión a ONNX con versión 17 del conjunto de operadores, aplicando simplificación del grafo, fusión de capas de normalización por lotes en convoluciones y eliminación de nodos redundantes (ONNX Runtime, 2026). La segunda etapa aplicó cuantización posterior al entrenamiento: para CPU se empleó el esquema S8S8 con operadores de cuantización y desquantización, y para GPU se utilizó TensorRT con precisión FP16 e INT8 con calibración por percentiles (Jacob et al., 2018). La tercera etapa verificó empíricamente la latencia y el throughput de cada configuración en el hardware objetivo, cuyos resultados se presentan en la sección 4.1.

3.6 Métricas de evaluación

La Tabla 9 sistematiza las métricas empleadas, las cuales se seleccionaron de forma que cada objetivo específico quedara vinculado a una medida verificable.

Tabla 9

Métricas de evaluación por módulo y criterio de éxito

Módulo	Métrica principal	Métricas complementarias	Criterio de éxito
Detección de defectos	mAP@0.5	mAP@0.5:0.95, precisión, exhaustividad, F1, latencia y throughput	mAP@0.5 > 0.80 y latencia < 100 ms
Mantenimiento predictivo	ROC-AUC	Exactitud, precisión, exhaustividad, F1, PR-AUC y error absoluto medio para RUL	ROC-AUC > 0.90
Recuperación documental	Recall@10	Recall@5, precisión@K, rango recíproco medio y latencia de recuperación	Recall@10 > 0.85
Explicabilidad	Consistencia entre ejecuciones	Fidelidad local medida como coeficiente de determinación entre predicción y explicación	Fidelidad local > 0.80
Plataforma	Latencia de extremo a extremo	Rendimiento en solicitudes por segundo y tasa de error	Latencia < 200 ms y error < 1 %

Nota. Elaboración propia. Los umbrales corresponden a los objetivos específicos declarados en la sección 1.3.2.

3.7 Procedimiento experimental y análisis estadístico

Todos los modelos se entrenaron cinco veces con semillas aleatorias distintas, y las métricas se reportan como media acompañada de la desviación estándar y del intervalo de confianza al 95 %. Esta práctica permite distinguir las mejoras atribuibles al diseño de las fluctuaciones propias del proceso de entrenamiento. Las comparaciones entre modelos se evaluaron mediante remuestreo bootstrap con 1 000 réplicas sobre el conjunto de prueba, con el fin de estimar la distribución de las diferencias de ROC-AUC y determinar si el intervalo de confianza de la diferencia excluye el valor cero.

3.8 Consideraciones éticas y gobernanza de los datos

El proyecto incorpora tres salvaguardas. La primera es la privacidad: los datos de sensores y las imágenes empleadas son sintéticos o de dominio público, y en un despliegue real el sistema debería anonimizar los rostros capturados por las cámaras de EPP. La segunda es la trazabilidad: cada predicción conserva la versión del modelo, el identificador de la solicitud y las variables que más contribuyeron a la decisión, lo que permite reconstruir el razonamiento ante una auditoría. La tercera es la supervisión humana: las alertas críticas se presentan como recomendaciones y no como órdenes automáticas, de modo que la decisión final permanece en el operador responsable.

3.9 Reproducibilidad

Para garantizar la reproducibilidad se fijaron las versiones de todas las dependencias en un archivo de requisitos, se documentó la semilla aleatoria de cada ejecución y se versionaron los datos, los pesos de los modelos y el diccionario de variables. El Apéndice A describe la estructura del repositorio, el Apéndice B la lista de verificación de reproducibilidad y el Apéndice C los comandos de despliegue del sistema.

4. RESULTADOS

4.1 Detección de defectos industriales


El modelo YOLOv11-Large ajustado alcanzó un mAP@0.5 de 0.837 sobre el conjunto de prueba, valor que supera en 0.037 el umbral comprometido de 0.80. La Tabla 10 presenta el desempeño global y la Figura 3 desagrega el resultado por clase de defecto.

Tabla 10

Desempeño global del modelo de detección de defectos (conjunto de prueba, $n = 930$)

Métrica	Valor	Intervalo de confianza al 95 %	Umbral objetivo	Estado
mAP@0.5	0.837	[0.829, 0.845]	> 0.800	Cumplido
mAP@0.5:0.95	0.511	[0.500, 0.522]	No definido	Informativo
Precisión	0.812	[0.803, 0.821]	No definido	Informativo
Exhaustividad	0.798	[0.789, 0.807]	No definido	Informativo
F1-Score	0.805	[0.796, 0.814]	No definido	Informativo

Nota. Elaboración propia. Los intervalos de confianza se calcularon mediante remuestreo bootstrap con 1 000 réplicas.

Figura 3*Average Precision por clase de defecto en el conjunto de prueba*

Nota. Elaboración propia. La línea discontinua representa el mAP@0.5 global y la línea punteada el umbral comprometido de 0.80.

La clase grieta obtuvo el mejor desempeño, con un Average Precision de 0.930, comportamiento explicable por sus características visuales distintivas: bordes definidos, alta relación de aspecto y contraste elevado respecto del fondo. En el extremo opuesto, la clase poro alcanzó 0.700, resultado atribuible a su similitud con el ruido de textura de la superficie y a la reducida área de las regiones anotadas, que dificulta la discriminación en resoluciones moderadas. Las clases intermedias —corrosión con 0.890, abolladura con 0.860, rayadura con 0.840 y mancha con 0.800— presentan un comportamiento consistente con la

complejidad visual esperada para cada patología. La Tabla 11 detalla estos resultados junto con el soporte de cada clase.

Tabla 11

Desempeño desagregado por clase de defecto

Clase	AP@0.5	Precisión	Exhaustividad	F1-Score	Soporte	Desviación respecto del mAP global
Grieta	0.930	0.902	0.894	0.898	180	+0.093
Corrosión	0.890	0.861	0.848	0.854	165	+0.053
Abolladura	0.860	0.834	0.821	0.827	150	+0.023
Rayadura	0.840	0.817	0.803	0.810	175	+0.003
Mancha	0.800	0.776	0.762	0.769	140	-0.037
Poro	0.700	0.681	0.664	0.672	120	-0.137
Promedio	0.837	0.812	0.798	0.805	930	No aplica

Nota. Elaboración propia. El promedio de los valores de AP por clase coincide con el mAP@0.5 global reportado.

El benchmark de latencia se ejecutó sobre una GPU NVIDIA T4 con imágenes de 640×640 y lote unitario, configurando la inferencia en modo síncrono para reflejar el peor caso de uso en una línea de producción. La Tabla 12 y la Figura 4 resumen los resultados.

Tabla 12


Benchmark de latencia y throughput por configuración de inferencia

Configuración	Latencia media (ms)	Latencia p95 (ms)	Throughput (FPS)	Aceleración relativa	Reducción de latencia
PyTorch FP32	78.3	91.2	12.8	1.0 ×	Línea base
ONNX FP32	52.1	60.4	19.2	1.5 ×	33.5 %
ONNX FP16	31.4	36.8	31.8	2.5 ×	59.9 %
TensorRT FP16	18.7	22.1	53.5	4.2 ×	76.1 %
TensorRT INT8	12.4	15.3	80.6	6.3 ×	84.2 %

Nota. Elaboración propia. Mediciones sobre GPU NVIDIA T4, imagen de 640×640 píxeles y lote unitario; promedio de 500 iteraciones tras 50 iteraciones de calentamiento.

Figura 4

Compromiso entre latencia y throughput según la configuración de inferencia



Nota. Elaboración propia. La línea discontinua señala el requisito de latencia inferior a 100 ms.

El objetivo de latencia inferior a 100 ms se cumple en las cinco configuraciones evaluadas, lo que otorga margen de decisión al equipo de ingeniería. La configuración TensorRT INT8 ofrece una aceleración de $6.3 \times$ respecto de la línea base y una reducción de latencia del 84.2 %, con un throughput de 80.6 imágenes por segundo. Conviene precisar que la ganancia máxima se observa al combinar la exportación a ONNX con la compilación en TensorRT: la exportación aislada aporta el 33.5 % de la reducción y la cuantización el resto. Esta descomposición resulta útil porque indica que, en

hardware sin soporte para TensorRT, una reducción superior al 50 % sigue siendo alcanzable mediante ONNX en precisión mixta.

4.2 Mantenimiento predictivo


El ensemble XGBoost-LSTM superó a ambos modelos individuales en las cinco métricas evaluadas. La Tabla 13 presenta la comparación y la Figura 5 las curvas ROC correspondientes.

Tabla 13

Comparación de desempeño de los modelos de mantenimiento predictivo ($n = 6\,150$ ventanas; 2 330 fallas reales)

Modelo	Exactitud	Precisión	Exhaustividad	F1-Score	ROC-AUC	PR-AUC
XGBoost individual	0.894	0.872	0.845	0.858	0.923	0.901
LSTM individual	0.876	0.855	0.811	0.833	0.901	0.878
Ensemble XGBoost-LSTM	0.912	0.894	0.871	0.882	0.941	0.924
Diferencia del ensemble frente a XGBoost	+0.018	+0.022	+0.026	+0.024	+0.018	+0.023

Nota. Elaboración propia. La diferencia de ROC-AUC del ensemble frente a XGBoost presenta un intervalo de confianza al 95 % de [0.009, 0.027], calculado mediante remuestreo bootstrap, lo que indica una mejora estadísticamente distinguible de cero.

Figura 5*Curvas ROC de los modelos individuales y del ensemble*


Nota. Elaboración propia. Los marcadores señalan el punto de operación seleccionado para cada modelo.

La matriz de confusión desagrega el origen de los aciertos y de los errores, información que las métricas agregadas no revelan. La Figura 6 presenta las matrices de los tres modelos sobre el mismo conjunto de prueba, lo que permite una comparación directa del patrón de error.

Figura 6

Matrices de confusión de los modelos evaluados sobre el conjunto de prueba

Matrices de confusión sobre el conjunto de prueba (n = 6 150)



Nota. Elaboración propia. VN = verdaderos negativos; FP = falsos positivos; FN = falsos negativos; VP = verdaderos positivos.

El ensemble redujo los falsos negativos de 360 a 300 frente a XGBoost, es decir, 60 fallas que el modelo individual no habría detectado pasan a identificarse correctamente. En términos operativos, esta reducción equivale a disminuir en un 16.7 % la probabilidad de una parada no planificada por falla no anticipada. El costo asociado es una contracción de los falsos positivos, que pasan de 290 a 240, lo que representa una mejora simultánea en ambas dimensiones del error y explica el aumento del ROC-AUC. La exhaustividad del ensemble (0.871) es coherente con el interés del proyecto, que prioriza detectar la falla sobre evitar la alerta, dado que el costo de un falso negativo supera al de una inspección preventiva innecesaria.

Para verificar que la ponderación elegida no fuera un artefacto de la partición de datos, se ejecutó un análisis de sensibilidad sobre el peso asignado a cada componente. La Tabla 14 muestra los resultados.

Tabla 14

Análisis de sensibilidad de la ponderación del ensemble

Ponderación (XGBoost / LSTM)	ROC-AUC	F1-Score	Exactitud
0.5 / 0.5	0.933	0.874	0.905
0.6 / 0.4 (configuración seleccionada)	0.941	0.882	0.912
0.7 / 0.3	0.936	0.877	0.908
0.8 / 0.2	0.928	0.869	0.901
0.9 / 0.1	0.924	0.862	0.896


Nota. Elaboración propia. La configuración seleccionada maximiza el ROC-AUC y el F1-Score de forma simultánea.

El análisis muestra que la superficie de desempeño es suave en torno a la ponderación seleccionada, con variaciones inferiores a 0.008 de ROC-AUC entre 0.5/0.5 y 0.7/0.3. Este resultado indica que el modelo no depende de una calibración frágil del peso, propiedad deseable en un sistema que deberá mantenerse en operación con datos cambiantes.

La explicabilidad se evaluó mediante TreeSHAP, cuyos valores de importancia se presentan en la Figura 7. La vibración en el eje Z, medida como desviación estándar en ventana móvil de diez muestras, encabeza la lista con una importancia media de 0.234, seguida por la tasa de cambio de la temperatura del

motor, con 0.189. Este hallazgo es consistente con la física del problema: los defectos incipientes en rodamientos y engranajes se manifiestan primero como un incremento de la energía vibratoria en el eje transversal a la carga.

Figura 7
Importancia media de las variables según TreeSHAP



Nota. Elaboración propia. Las barras resaltadas superan el corte de referencia de 0.10 de importancia media absoluta.

Las cinco variables principales concentran el 78.9 % de la importancia total, mientras que las tres restantes aportan el 21.1 %. Desde una perspectiva de ingeniería, este resultado tiene una consecuencia práctica relevante: es posible simplificar el sistema de adquisición de datos y prescindir de los sensores asociados a las variables con menor contribución, sin degradar de manera apreciable el desempeño del modelo. La fidelidad local de las explicaciones, medida como coeficiente de determinación entre la predicción y la

reconstrucción a partir de los valores SHAP, alcanzó 0.94, valor que supera el umbral de 0.80 comprometido y respalda la validez de las explicaciones presentadas al operador.

4.3 Pipeline de recuperación documental

El pipeline indexó 15 documentos técnicos que totalizaron 1 247 fragmentos y respondió un conjunto de 120 consultas con fragmento relevante anotado. La Tabla 15 presenta los resultados.

Tabla 15


Resultados del pipeline de recuperación aumentada

Métrica	Valor	Intervalo de confianza al 95 %	Umbral objetivo	Estado
Recall@5	0.890	[0.868, 0.912]	No definido	Informativo
Recall@10	0.940	[0.919, 0.961]	> 0.850	Cumplido
Rango recíproco medio	0.840	[0.814, 0.866]	No definido	Informativo
Precisión@5	0.712	[0.688, 0.736]	No definido	Informativo
Latencia de recuperación	45 ms	No aplica	No definido	Informativo
Confianza promedio de la respuesta	0.820	[0.795, 0.845]	No definido	Informativo

Nota. Elaboración propia. El recall se calcula por consulta y se promedia sobre las 120 consultas anotadas.

Figura 8

Comparación del recall entre la búsqueda densa pura y la búsqueda híbrida



Nota. Elaboración propia. La línea punteada representa el umbral comprometido de 0.85 de recall@10.

La búsqueda híbrida mejoró el recall@10 de 0.83 a 0.94, lo que representa un incremento relativo del 13.3 % respecto de la búsqueda densa pura, en línea con el comportamiento reportado en la literatura (Golchian, 2026). El análisis de los casos de éxito sugiere que la ganancia proviene de tres tipos de consulta: aquellas que mencionan códigos de componente, las que emplean nomenclatura normativa y las que combinan un término técnico con una referencia numérica. En los tres casos, el recuperador disperso localiza coincidencias léxicas exactas que el recuperador denso diluye en el espacio de embeddings, mientras que el recuperador denso aporta valor en las consultas formuladas con vocabulario

coloquial. El rango recíproco medio de 0.840 indica que, en promedio, el primer fragmento relevante aparece en la segunda posición del ranking, resultado que resulta adecuado para un sistema de asistencia donde el operador revisa las tres primeras respuestas.

4.4 Monitoreo de equipo de protección personal

El monitor de EPP procesó el flujo de video a 25 cuadros por segundo, con una latencia media de 42 ms, y registró una tasa de cumplimiento promedio del 87.3 % durante una simulación de turno de ocho horas. En ese intervalo se generaron 12 alertas críticas por ausencia de casco o arnés en zonas de riesgo. La Tabla 16 y la Figura 9 detallan el comportamiento por zona de la planta.

Tabla 16

Cumplimiento de EPP por zona de la planta durante la simulación de turno


Zona	Cumplimiento promedio	Alertas críticas	Observación
Soldadura	91.2 %	1	Zona con mayor supervisión y control de acceso
Prensado	88.4 %	2	Riesgo alto; el cumplimiento se mantiene estable
Ensamble	87.1 %	3	Cumplimiento cercano al promedio general
Almacén	84.2 %	4	Zona con mayor circulación de personal externo
Pintura	85.8 %	2	Uso de protección respiratoria adicional

Total del turno	87.3 %	12	Promedio ponderado por tiempo de exposición
-----------------	--------	----	---

Nota. Elaboración propia. La ponderación considera el tiempo de permanencia de cada operador en la zona.

Figura 9

Cumplimiento de EPP durante el turno y desagregación por zona



Nota. Elaboración propia. Las líneas verticales señalan los instantes en que se generó una alerta crítica.

El patrón de resultados revela una relación inversa entre el cumplimiento y la circulación de personal: las zonas con acceso restringido, como soldadura, presentan el cumplimiento más alto (91.2 %), mientras que el almacén, que recibe personal externo con mayor frecuencia, registra el más bajo (84.2 %). Esta

observación sugiere que las intervenciones de seguridad deberían concentrarse en los puntos de tránsito y no únicamente en las áreas de riesgo evidente, conclusión que solo resulta visible cuando los datos se analizan de forma desagregada por zona.

4.5 Rendimiento de la plataforma

La API REST y el tablero se evaluaron con una prueba de carga sostenida de 150 solicitudes por segundo durante diez minutos, con un único proceso de trabajo. La Tabla 17 resume el rendimiento por endpoint.

Tabla 17

Rendimiento de los endpoints de la API bajo carga sostenida

Endpoint	Método	Función	Latencia media (ms)	Latencia p95 (ms)	Tasa de error
/health	GET	Verificación de estado y disponibilidad de GPU	3	6	0.00 %
/vision/defects/detect	POST	Detección de defectos y EPP	120	148	0.12 %
/maintenance/predict	POST	Predicción de riesgo de falla	26	34	0.05 %
/rag/query	POST	Consulta a manuales técnicos	35	52	0.07 %


Nota. Elaboración propia. Prueba de carga de 150 solicitudes por segundo durante diez minutos con un proceso de trabajo.

El endpoint de visión concentra la mayor latencia (120 ms) porque incluye el preprocesamiento de la imagen, la inferencia y la serialización de las

detecciones; aun así, su latencia p95 de 148 ms permanece por debajo del umbral de 200 ms comprometido para el servicio de extremo a extremo, distinto del requisito de 100 ms que aplica exclusivamente a la inferencia del modelo. La distinción entre ambos umbrales resulta metodológicamente importante: el tiempo de inferencia mide el desempeño del modelo, mientras que la latencia del endpoint mide el desempeño del sistema completo, incluidos el transporte de red y la capa de aplicación. La Figura 10 reproduce el tablero de monitoreo con los indicadores descritos.

Figura 10

Prototipo del tablero de monitoreo con indicadores, series temporales y registro de eventos



Nota. Elaboración propia. El tablero se actualiza con un intervalo configurable entre uno y diez segundos.

4.6 Estabilidad de los resultados

Para determinar si las métricas reportadas son reproducibles o dependen de una inicialización afortunada, cada modelo se entrenó cinco veces con semillas distintas. La Tabla 18 presenta la media, la desviación estándar y el intervalo de confianza al 95 % de las métricas principales.

Tabla 18

Estabilidad de las métricas principales sobre cinco ejecuciones independientes

Métrica	Media	Desviación estándar	Intervalo de confianza al 95 %	Coefficiente de variación
mAP@0.5 (visión)	0.837	0.008	[0.829, 0.845]	0.96 %
mAP@0.5:0.95 (visión)	0.511	0.011	[0.500, 0.522]	2.15 %
ROC-AUC (ensemble)	0.941	0.006	[0.935, 0.947]	0.64 %
F1-Score (ensemble)	0.882	0.009	[0.873, 0.891]	1.02 %
Recall@10 (recuperación)	0.940	0.021	[0.919, 0.961]	2.23 %
Rango recíproco medio (recuperación)	0.840	0.026	[0.814, 0.866]	3.10 %

Nota. Elaboración propia. El coeficiente de variación se expresa como porcentaje de la media.

Todos los coeficientes de variación son inferiores al 3.2 %, lo que indica que los resultados son estables frente a la inicialización aleatoria. El módulo con mayor variabilidad es el de recuperación documental, comportamiento esperable porque el conjunto de evaluación contiene 120 consultas y el redondeo de cada

recuperación es sensible a variaciones marginales en el ordenamiento del ranking. El módulo de visión es el más estable, con una variación inferior al 1 %.

4.7 Verificación del cumplimiento de los objetivos

La Tabla 19 contrasta cada objetivo específico con el resultado obtenido, y la Figura 11 expresa el margen alcanzado sobre la meta declarada. Esta verificación responde al séptimo objetivo específico y al criterio de terminado definido en la sección 3.1.

Tabla 19


Verificación cuantitativa de los objetivos específicos

Objetivo	Métrica	Meta	Resultado	Margen	Estado
1	mAP@0.5	> 0.800	0.837	+4.6 %	Cumplido
1	Latencia de inferencia	< 100 ms	12.4 ms	-87.6 %	Cumplido
2	ROC-AUC	> 0.900	0.941	+4.6 %	Cumplido
3	Recall@10	> 0.850	0.940	+10.6 %	Cumplido
4	Fidelidad local de SHAP	> 0.800	0.940	+17.5 %	Cumplido
5	Cuantización INT8 y FP16	Implementada	Implementada y verificada	No aplica	Cumplido
6	Despliegue con Docker, API y tablero	Funcional	Funcional y probado bajo carga	No aplica	Cumplido
7	Verificación con evidencia cuantitativa	Documentada	Tablas 19 y 24 y Figuras 10 y 11	No aplica	Cumplido

Nota. Elaboración propia. El margen se calcula como la diferencia relativa entre el resultado y la meta declarada.

Figura 11

Margen de cumplimiento obtenido en cada objetivo específico cuantificable



Nota. Elaboración propia. Las barras expresan el porcentaje de holgura respecto de la meta declarada en la sección 1.3.2.

Los siete objetivos específicos se cumplieron. El margen más estrecho corresponde a los objetivos de precisión de visión y de mantenimiento predictivo, ambos con un 4.6 % de holgura, mientras que la latencia presenta el margen más amplio, con una reducción del 87.6 % respecto del límite establecido.

4.8 Síntesis de los resultados

Los resultados admiten una lectura integrada. En el módulo de visión, la combinación de una arquitectura de última generación con una optimización agresiva permitió cumplir simultáneamente los requisitos de precisión y de latencia, que en la práctica suelen entrar en conflicto. En el módulo de mantenimiento predictivo, la evidencia respalda la hipótesis central del proyecto: la complementariedad entre un modelo tabular y un modelo secuencial produce una mejora medible y estadísticamente distinguible, con una reducción del 16.7 % en los falsos negativos respecto del mejor componente individual. En el módulo de recuperación documental, la fusión de recuperadores densos y dispersos confirmó que la terminología técnica industrial exige estrategias híbridas. Finalmente, la estabilidad de las métricas a lo largo de cinco ejecuciones refuerza la confiabilidad de las conclusiones y permite afirmar que los resultados no son un artefacto de una partición favorable.

5. DISCUSIÓN

5.1 Interpretación de los resultados

El hallazgo central de este trabajo es que la integración multimodal no constituye una suma de componentes independientes, sino que genera tres sinergias verificables. La primera es de naturaleza diagnóstica: la coincidencia temporal entre una anomalía de vibración detectada por el módulo de series temporales y un defecto superficial detectado por el módulo de visión permite formular hipótesis causales que ninguno de los dos módulos podría sostener por separado. La segunda es de naturaleza explicativa: las variables que el análisis SHAP identifica como más influyentes en la predicción de fallas coinciden con los indicadores que los manuales técnicos del corpus describen como señales tempranas de degradación, lo que otorga validez externa a las explicaciones del modelo. La tercera es de naturaleza operativa: la unificación de los tres módulos en un único tablero reduce el tiempo de interpretación por parte del operador, pues evita la consulta de sistemas independientes.

El mAP@0.5 de 0.837 obtenido resulta equiparable al mejor valor reportado por Li et al. (2026) para YOLOv11-LLR en el conjunto NEU-DET, con la salvedad metodológica de que los conjuntos de datos difieren y, por tanto, la comparación

es indicativa y no concluyente. En el módulo de mantenimiento predictivo, el ROC-AUC de 0.941 sitúa al ensemble en el rango de desempeño que la literatura asocia con sistemas aptos para producción, y el análisis bootstrap confirma que la mejora frente a XGBoost no es atribuible al azar. En el módulo de recuperación, el recall@10 de 0.940 supera en 0.03 el valor de referencia reportado para sistemas industriales con búsqueda híbrida (Golchian, 2026).

Un aspecto que merece discusión específica es la asimetría entre los dos tipos de error del clasificador de fallas. El sistema prioriza la exhaustividad sobre la precisión, decisión de diseño coherente con el contexto industrial, donde el costo de una parada no planificada supera al de una inspección preventiva innecesaria. Esta elección debe hacerse explícita ante el usuario del sistema, porque implica que una de cada nueve alertas aproximadamente no corresponderá a una falla real. Presentar esa proporción de forma transparente es preferible a prometer una exactitud global que oculte la distribución del error.

5.2 Comparación con el estado del arte

La Tabla 20 sitúa los resultados del proyecto frente a los valores publicados en la literatura revisada. Las cifras deben interpretarse con cautela, pues los conjuntos de datos empleados difieren en tamaño, origen y nivel de dificultad.

Tabla 20*Comparación de los resultados con los valores reportados en la literatura*

Referencia	Modelo o sistema	Conjunto de datos	Métrica reportada	Resultado del proyecto	Diferencia relativa
Li et al. (2026)	YOLOv11-LLR	NEU-DET	mAP@0.5 = 0.837	0.837	0.0 %
Li et al. (2026)	YOLOv11-LLR	GC10-DET	mAP@0.5 = 0.708	0.837	+18.2 %
Zhang (2026)	EMSD-YOLO	GC10-DET	mAP@0.5 = 0.762	0.837	+9.8 %
Kocak (2025)	YOLO11	Defectos en baldosas	mAP@0.5 = 0.812	0.837	+3.1 %
Golchian (2026)	Pipeline RAG industrial	Corpus técnico	Recall@10 = 0.910	0.940	+3.3 %
Presente trabajo	Plataforma multimodal integrada	Conjuntos sintéticos propios	mAP@0.5 = 0.837; ROC-AUC = 0.941; recall@10 = 0.940	No aplica	No aplica

Nota. Elaboración propia. Las diferencias relativas son indicativas, ya que los conjuntos de datos de referencia no son equivalentes a los empleados en este proyecto.

El resultado más relevante de esta comparación no es la magnitud de las diferencias, sino su coherencia: los tres módulos alcanzan valores del mismo orden que los reportados en la literatura especializada, lo que sugiere que la metodología empleada es sólida. Sin embargo, la ventaja diferencial del proyecto no reside en superar una métrica aislada, sino en integrar tres dominios tecnológicos bajo una misma capa de servicios con explicabilidad transversal, aspecto que la literatura revisada aborda con menor frecuencia.

5.3 Implicaciones prácticas

Los resultados admiten tres aplicaciones inmediatas. La primera es la inspección automatizada de calidad, donde la latencia de 12.4 ms habilita la clasificación en línea a velocidades de producción industrial sin necesidad de acumular piezas en un búfer. La segunda es la programación de mantenimiento basada en condición, donde las explicaciones SHAP permiten justificar ante el área de mantenimiento por qué se recomienda intervenir un equipo determinado. La tercera es la capacitación y el soporte operativo, donde el pipeline de recuperación reduce el tiempo de búsqueda de procedimientos en manuales extensos.

Desde la perspectiva de la gestión tecnológica, la descomposición de la ganancia de latencia constituye un hallazgo transferible: la exportación a un formato intermedio aporta una mejora sustancial antes de recurrir a hardware especializado, lo que reduce la barrera de adopción en plantas que no cuentan con aceleradores dedicados.

5.4 Limitaciones

A continuación, se enumeran las limitaciones del trabajo, ordenadas por su impacto potencial sobre la validez de los resultados.

1. Uso de datos sintéticos. Aunque los datos de sensores se generaron con modelos físicos simplificados y los datos de visión incorporan augmentación realista, la validación en datos reales de planta resulta indispensable para confirmar la generalización de los hallazgos. La brecha entre el desempeño sintético y el productivo suele ser la principal fuente de sobreestimación en proyectos de este tipo.
2. Prevalencia artificialmente alta de la clase de falla. El generador etiquetó como falla el 37.9 % de las ventanas, proporción muy superior a la observada en plantas reales, donde la prevalencia de fallas rara vez supera el 5 %. Esta decisión evitó el colapso del clasificador hacia la clase mayoritaria, pero también infla las métricas de exactitud y reduce la transferibilidad de los valores absolutos a entornos productivos con fuerte desbalance.
3. Pipeline RAG sin modelo generativo. La generación de respuestas emplea plantillas con contexto inyectado en lugar de un modelo de lenguaje ajustado, lo que limita la fluidez y la capacidad de síntesis de las respuestas. La integración de un modelo generativo está planificada para la siguiente versión del sistema.

4. Escalabilidad del almacén vectorial. ChromaDB resulta adecuado para el volumen actual de 1 247 fragmentos, pero para corpus de millones de documentos requeriría particionamiento o migración a una solución distribuida.
5. Sesgo en la detección de EPP. El modelo puede presentar menor precisión en condiciones de iluminación extrema, como contraluz o sombras duras, no representadas en el conjunto de entrenamiento.
6. Alcance de la explicabilidad. La evaluación de la fidelidad de las explicaciones se limita al módulo de mantenimiento predictivo; los módulos de visión y de recuperación carecen por ahora de un mecanismo equivalente.

5.5 Amenazas a la validez

La Tabla 21 identifica las principales amenazas a la validez del estudio y las estrategias de mitigación aplicadas o pendientes.

Tabla 21

Amenazas a la validez y estrategias de mitigación

Tipo de validez	Amenaza identificada	Mitigación aplicada	Acción pendiente
Interna	Fuga de información entre subconjuntos	Partición temporal y por documento; estratificación por clase	Auditoría automatizada de similitud entre conjuntos
Interna	Sensibilidad a la inicialización	Cinco ejecuciones con semillas distintas y	Incrementar a diez ejecuciones

	aleatoria	reporte de intervalos de confianza	
De constructo	Métricas no alineadas con el objetivo del negocio	Umbrales vinculados a objetivos específicos y verificación trazable	Definir el costo monetario de cada tipo de error
Externa	Datos sintéticos no representativos de la planta	Augmentación con condiciones reales documentadas	Validación con datos productivos en un piloto
Estadística	Comparaciones sin prueba de significancia	Remuestreo bootstrap con 1 000 réplicas	Ampliar el tamaño del conjunto de prueba
Ecológica	Simulación en lugar de operación real	Simulación de turno completo de ocho horas	Prueba de concepto en línea piloto

Nota. Elaboración propia. La clasificación de amenazas sigue la distinción habitual entre validez interna, de constructo, externa y estadística.

5.6 Trabajo futuro

A partir de las limitaciones identificadas, se proponen seis líneas de trabajo. Primero, implementar aprendizaje federado para entrenar modelos entre múltiples plantas industriales sin compartir datos crudos. Segundo, integrar modelos de segmentación de propósito general para obtener mediciones dimensionales precisas de cada defecto, más allá de la caja delimitadora. Tercero, desarrollar un gemelo digital que permita evaluar escenarios de mantenimiento hipotéticos. Cuarto, consolidar una práctica de operaciones de aprendizaje automático con seguimiento de experimentos, versionado de datos y validación automática de su calidad. Quinto, incorporar generación multimodal en el pipeline de recuperación, de modo que las respuestas incluyan diagramas técnicos. Sexto, establecer una auditoría continua de equidad que detecte sesgos en la asignación de alertas de seguridad según la zona o el turno laboral.

6. CONCLUSIONES

OmniSafety AI demuestra que resulta técnicamente viable y operacionalmente efectivo integrar múltiples modalidades de inteligencia artificial —visión, series temporales y procesamiento de lenguaje natural— en una plataforma unificada para entornos industriales. Los resultados obtenidos permiten formular las siguientes conclusiones.

1. El modelo YOLOv11-L, optimizado con TensorRT INT8, cumple simultáneamente los requisitos de latencia y de precisión para la inspección visual en tiempo real, con 12.4 ms por imagen y un mAP@0.5 de 0.837, equivalente al mejor valor reportado en la literatura para conjuntos de datos comparables.
2. El ensemble XGBoost-LSTM proporciona predicciones de falla con un ROC-AUC de 0.941 y reduce los falsos negativos en un 16.7 % respecto del mejor modelo individual, con explicaciones SHAP que identifican la vibración en el eje Z y la tasa de cambio de la temperatura del motor como los indicadores más críticos.
3. El pipeline de recuperación con búsqueda híbrida alcanza un recall@10 de 0.940, lo que representa una mejora relativa del 13.3 % frente a la

- búsqueda densa pura y democratiza el acceso al conocimiento técnico almacenado en manuales extensos.
4. La arquitectura de microservicios con Docker permite un despliegue escalable, con una separación clara entre las capas de ingesta, procesamiento y presentación, y con un rendimiento sostenido de 150 solicitudes por segundo en una configuración de un solo proceso de trabajo.
 5. La explicabilidad integrada mediante SHAP satisface los requisitos de gobernanza y auditoría que condicionan la adopción regulatoria de la inteligencia artificial en industrias críticas, con una fidelidad local de 0.940.
 6. La estabilidad de las métricas a lo largo de cinco ejecuciones independientes, con coeficientes de variación inferiores al 3.2 %, respalda la reproducibilidad de los resultados y la confiabilidad de las conclusiones.

El proyecto articula de manera efectiva los conocimientos de los seis cuatrimestres del plan de estudios, desde los fundamentos de programación y álgebra lineal hasta el despliegue en la nube y la ética de la inteligencia artificial, y evidencia la madurez del equipo para desarrollar soluciones integrales en

contextos industriales reales. Como línea de continuidad inmediata, se recomienda validar la plataforma con datos productivos de una planta piloto, con el fin de cuantificar la brecha entre el desempeño sintético reportado en este documento y el desempeño operativo en condiciones reales.

REFERENCIAS

- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785-794). Association for Computing Machinery. <https://doi.org/10.1145/2939672.2939785>
- Explainable AI (XAI) for transparent resource allocation in public safety communications networks. (2026, 19 de marzo). Scientific Reports. <https://www.nature.com/articles/s41598-026-43440-9>
- FutureAGI. (2026, 14 de mayo). ROI of AI explainability tools 2026: SHAP, LIME, Captum. FutureAGI Blog. <https://futureagi.com/blog/roi-ai-explainability-2025/>
- Golchian, P. (2026, 7 de abril). RAG pipelines in production: Vector database benchmarks, chunking strategies, and hybrid search data. Dev.to. <https://dev.to/pooyagolchian/rag-pipelines-in-production-vector-database-benchmarks-chunking-strategies-and-hybrid-search-data-gbl>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., Adam, H., & Kalenichenko, D. (2018). Quantization and training of neural networks for

efficient integer-arithmetic-only inference. En Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 2704-2713).

IEEE. <https://doi.org/10.1109/CVPR.2018.00286>

Kocak, C. D. (2025, 29 de noviembre). Tile defect detection YOLO11 [Modelo de aprendizaje automático]. Hugging Face.

<https://huggingface.co/candenizkocak/tile-defect-detection-yolo11>

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H.,

Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020).

Retrieval-augmented generation for knowledge-intensive NLP tasks. En

Advances in Neural Information Processing Systems (Vol. 33, pp.

9459-9474). Curran Associates.

<https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>

Li, J., Yang, Y., Geng, R., Chang, Y., Jiang, Y., Wu, K., & Lu, J. (2026). YOLOv11-LLR:

An enhanced framework for steel surface defect detection in industrial

settings. Applied Sciences, 16(10), 4609. <https://doi.org/10.3390/app16104609>

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model

predictions. En Advances in Neural Information Processing Systems (Vol.

30, pp. 4765-4774). Curran Associates.

<https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>

ONNX Runtime. (2026). Quantizing ONNX models [Documentación técnica].

Microsoft.

<https://onnxruntime.ai/docs/performance/model-optimizations/quantization.html>

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You only look once:

Unified, real-time object detection. En Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (pp. 779-788). IEEE.

<https://doi.org/10.1109/CVPR.2016.91>

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using

Siamese BERT-networks. En Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (pp. 3982-3992).

Association for Computational Linguistics.

<https://doi.org/10.18653/v1/D19-1410>

Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller,

K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. Machine Learning and Knowledge

Extraction, 3(2), 392-413. <https://doi.org/10.3390/make3020020>

Zhang, W. H. (2026). EMSD-YOLO: A surface defect detection model based on YOLOv11. Journal of Manufacturing Systems. Avance de publicación en línea. <https://www.sciencedirect.com/science/article/pii/S2667241326000030>

Repositorio Github

https://github.com/pitsburg8280-cmyk/Proyecto_OmniSafety_AI.git

APÉNDICE A. ESTRUCTURA DEL REPOSITORIO

El repositorio se organiza en carpetas que separan el código fuente, los datos, la configuración y la documentación, conforme a la Tabla 22.

Tabla 22

Estructura de directorios del repositorio y contenido principal

Directorio	Contenido	Artefactos principales
config/	Configuración global del sistema	Archivo de configuración en formato YAML
data/raw/	Datos originales	Imágenes, telemetría y documentos técnicos
data/processed/	Datos preprocesados	Matrices de características y particiones versionadas
data/models/	Modelos entrenados y optimizados	Pesos en PyTorch, ONNX y TensorRT
docs/figuras/	Ilustraciones del documento	Once figuras en formato PNG a 150 ppp
scripts/	Automatización	Generación de figuras y construcción del documento
src/api/	Servicio de API REST	Aplicación FastAPI con cuatro endpoints
src/dashboard/	Tablero de monitoreo	Aplicación Streamlit con cinco pestañas
src/nlp/	Procesamiento de lenguaje natural	Pipeline de recuperación aumentada
src/timeseries/	Series temporales	Modelo híbrido de mantenimiento predictivo
src/vision/	Visión por computadora	Detección de defectos y monitoreo de EPP
tests/	Pruebas automatizadas	Pruebas unitarias y de integración

Nota. Elaboración propia. La estructura facilita la separación entre código, datos y documentación.

APÉNDICE B. LISTA DE VERIFICACIÓN DE REPRODUCIBILIDAD

La Tabla 23 enumera los elementos verificados para permitir la reproducción de los resultados.

Tabla 23

Lista de verificación de reproducibilidad del proyecto

Elemento	Estado	Evidencia
Versiones de dependencias fijadas	Verificado	Archivo de requisitos con versiones exactas
Semillas aleatorias documentadas	Verificado	Registro de las cinco ejecuciones por modelo
Particiones de datos versionadas	Verificado	Archivos de índices por subconjunto
Diccionario de variables documentado	Verificado	Tabla 4 del presente documento
Artefactos de modelo versionados	Verificado	Pesos y archivos ONNX en data/models/
Comandos de despliegue documentados	Verificado	Apéndice C del presente documento
Métricas verificadas contra umbrales	Verificado	Tabla 19 del presente documento

Nota. Elaboración propia. Cada elemento cuenta con evidencia almacenada en el repositorio del proyecto.

APÉNDICE C. COMANDOS DE DESPLIEGUE

La puesta en marcha del sistema requiere ejecutar los comandos que se listan a continuación. El primero inicia la API REST, el segundo el tablero de monitoreo y el tercero la orquestación completa mediante contenedores.

```
uvicorn src.api.main:app --host 0.0.0.0 --port 8000  
streamlit run src/dashboard/app.py --server.port 8501  
docker compose up --build
```

La API queda disponible en el puerto 8000, con documentación interactiva en la ruta /docs, y el tablero en el puerto 8501. La verificación de estado se realiza mediante el endpoint /health, que además informa si el entorno dispone de aceleración por GPU.

APÉNDICE D. TRAZABILIDAD ENTRE OBJETIVOS, MÓDULOS Y EVIDENCIA

La Tabla 24 vincula cada objetivo específico con el módulo responsable y la evidencia presentada en el documento, con el fin de facilitar la evaluación y la auditoría del proyecto.

Tabla 24

Matriz de trazabilidad entre objetivos, componentes y evidencia

Objetivo	Módulo responsable	Artefacto del sistema	Evidencia en el documento
1	Visión	Detector de defectos	Tablas 10, 11 y 12; Figuras 3 y 4
2	Series temporales	Modelo híbrido de mantenimiento	Tablas 13 y 14; Figuras 5 y 6
3	Procesamiento de lenguaje natural	Pipeline de recuperación	Tabla 15; Figura 8
4	Explicabilidad	Módulo SHAP	Figura 7; fidelidad local de 0.940
5	Optimización	Exportación y cuantización	Tabla 12; sección 3.5
6	Despliegue	API, tablero y contenedores	Tabla 17; Figura 10; Apéndice C
7	Verificación	Trazabilidad de métricas	Tablas 18, 19 y 24; Figura 11

Nota. Elaboración propia. La matriz permite reconstruir la cadena de evidencia de cada objetivo declarado.